아폴라톡신 위해요소의 하이브리드 예측모델 개발 연구 보고서

식품안전정보원

Ⅰ. 데이터 전처리 부문

I. 데이터 전처리 부문

(작성 중)

1. 예측 모델링용 데이터 생성 절차

1.1 데이터 수집

□ 식품의약품안전처의 LIMS(Laboratory Information Management System) 데이터

○ 식품의약품안전처 출처 LIMS 데이터의 구성은 다음과 같음(아래 표[] 참고)

- 9개 종류의 LIMS 데이터 (2015년~2025년)
- 40개 종류의 검사 관련 구성 변수

데이터 종류	구성 변수		
제조수입	INSPCT_INSTT_CODE (검사 기관 코드)	PRDLST_NM (품목 명)	EXPR_IEM_NM (시험 항목 명)
품질검사	INSPCT_INSTT_NAME (검사 기관 명)	SPLORE_NM (시료명)	STNDRD_VALUE (규격 값)
기타	SPLORE_REQEST_NO1 (시료 의뢰번호)	SPLORE_QY (시료량)	RESULT_VALUE (결과 값)
수입검사	SPLORE_RCEPT_NO (시료 접수 번호)	SPLORE_WT (시료 무게)	EXPR_IEM_JDGMNT_NAME (시험항목 판정명)
모니터링	REQEST_DE (의뢰일자)	SPLORE_WT_UNIT_NAME (시료 무게 단위 코드)	REQEST_INSTT_RCEPT_NO (*설명 정보 없음*)
검사명령	JOB_REALM_NAME (업무분야명)	MNFCTUR_CMPNY_NM (제조회사 명)	ORGPLCE_NATION_CODE (원산지 국가 코드)
자가품질	INSPCT_PURPS_CODE (검사목적코드)	MNFCTUR_CMPNY_LOCPLC_NM (제조회사 소재지 명)	MNFCTUR_DE (제조 일)
수거검사	INSPCT_KND_CODE (검사종류코드)	PRDLST_MNFCTUR_STTEMNT_NO (품목 제조 신고 번호)	DISTB_DE (유통 일)
압몰수품	INSPCT_PURPS_NAME (검사목적명)	PROCESS_DE (처리 일)	PRLOAD_NM (선적항 명)
	INSPCT_KND_NAME (검사종류명)	TOT_EXPR_IEM_CNT (총 시험 항목 카운트)	IMPORT_ENTRPS_NM (수입 업체 명)
	REQEST_DEPT_NAME (의뢰 부서 코드)	JDGMNT_WORD_CODE (판정 용어 코드)	ETRYPT_DE (입항 일)
	REQEST_INFO_RM (의뢰 정보비고)	JDGMNT_WORD_NAME (판정 용어명)	PRDLST_CODE (품목 코드)
	SPLORE_SN (시료 순번)	SPLORE_STTUS_NAME (시료 상태 코드)	PRDUCT_NM (제품 명)

[그림 1] LIMS데이터 종류

[그림 2] LIMS데이터 구성변수

[표 1] 식품의약품안전처 출처 LIMS raw 데이터 구성

□ 외부 기후 데이터

○ 주로 식품이 재배되거나 보관된 환경 조건을 나타내며, 아플라톡신(곰팡이독소) 생성에 영향을 미치는 독립 변수(Independent Variables)로 활용함

○ 수집 기준

- 수집 기간: 2015년 ~ 2025년
- 수집 주기: 일 단위 데이터

○ 국립농업과학원 농업기상 데이터

- 수집 방법: Open API 활용 (농업기상 기본 관측데이터 조회 - 농업날씨365)
- 관측 지점: 전국 농업기상 관측소

○ 기상청 종관기상관측(ASOS) 데이터

- 수집 방법: 엑셀(Excel) 데이터 직접 다운로드
- 관측 지점: 기상청 기상관측 지점
- 활용 목적: 국립농업과학원 Open API의 '일조시간' 데이터 결측률이 높아, ASOS의 일일 '합계 일조시간(hr)'을 활용

○ 기상데이터는 총 온도, 습도 등의 총 10개 변수로 구성은 아래 표 []와 같음

	변수명	설명
1	tmprt_150	기온(150CM)
2	tmprt_150Top	기온(150CM)최고
3	tmprt_150Lwet	기온(150CM)최저
4	hd_150	습도(150CM)
5	arvlty_300	풍속(300CM)
6	arvlty_300Top	최대풍속(300CM)
7	afp	강수량
8	일조	일일 합계 일조시간
9	solrad_Qy	일사량
10	soil_Mitr_10	토양수분(10CM)

[표 2] 기상데이터 변수 구성

1.2 데이터 병합

○ 위치정보 추출

- 식품의약품안전처 아플라톡신 시험검사(LIMS) 데이터의 각 건별 주소('제조회사 소재지' 또는 '검사기관 주소')를 이용하여 공공데이터포털의 주소-좌표 변환 API를 통해 위도(latitude)와 경도(longitude) 정보를 조회함

  • '제조회사 소재지'가 존재하는 경우 우선 활용하고, 결측 시 '검사기관' 주소를 대체 사용함

- 주소 체계 및 정밀도 차이를 보정하기 위해 지오코딩(Geocoding) 과정을 수행하여 LIMS 데이터와 농촌진흥청 국립농업과학원 농업기상 상세 관측데이터(2015~2025)의 공간 기준을 일치시킴

○ 지오코딩으로 확보한 위·경도 정보를 활용하여, 각 제조회사/검사기관과 가장 인접한 농업기상관측소 지점을 탐색함

○ 공간 분석 기법을 적용하여, 가장 가까운 지점의 단일 관측값을 매칭하거나 일정 반경 내 다수 관측지점의 평균값을 활용함.

○ 시간 기준 매칭 및 집계

- LIMS 데이터의 시험검사일을 기준으로, 해당 일자를 중심으로 과거 60일 간의 기상 데이터를 추출함.
- 추출된 기상 데이터를 시계열 record 형태로 구성
- 아플라톡신 발생은 주로 고온다습한 환경에서 수확 전후에 집중되므로, 검사일 이전 기간의 기상 패턴을 반영하는 것이 중요함.

○ 최종 데이터 병합

- 위·경도 기반의 공간 매칭 및 시간 기준 집계 완료 후, 두 데이터를 시간(Time)과 공간(Location) 기준으로 병합함 (아래 표[] 참고)

단계	주요 작업
1. 위치정보 추출	주소 → 좌표 변환 및 공간 기준 통일
2. 시간 기준 매칭	기상 데이터 추출
3. 최종 데이터 병합	LIMS + 기상 데이터

[표 3] 데이터 병합 절차 요약

1.3 데이터 정제

□ 불필요 데이터 제거

○ ‘검사 판정 결과‘ 칼럼의 "상기실험확인함" 값을 갖는 데이터 행 제거

- LIMS 데이터의 ‘검사 판정 결과‘ 칼럼에는 ’적합‘, ’부적합‘, ’상기실험확인함‘의 3가지 값이 존재
- "상기실험확인함" 값의 의미가 불명확하여 이진 분류 모델 학습에 부적합
- "상기실험확인함" 값 제거 후 적합=0, 부적합=1로 인코딩

○ ‘검사종류‘ 칼럼의 ‘수입검사‘ 값을 갖는 값 제거

○ ‘검사 대상 종류’ 칼럼의 ‘축산물’ 값을 갖는 데이터행 제거

- 축산물은 아플라톡신 분석 대상이 아님

○ ‘품목명‘ 칼럼의 식품첨가물(’덱스트린‘, ’혼합제제‘)가 포함된 데이터 행 제거

- 식품첨가물은 아플라톡신 분석대상 품목이 아니라는 식정원 의견
- 데이터셋에서 '덱스트린', '혼합제제' 텍스트 검색결과 5건 발견 후 삭제

○ 불필요 데이터 제거 후 총 170,189개 데이터로 구성 (아래 표[] 참고)

구분	최초데이터 수	불필요 정보 제거 후 데이터 수	제거비율
전체 데이터	443,824	170,189	61.65%

[표 4] 불필요 데이터 제거 전후 비교표

□ 식품유형 분류

○ '품목명' 칼럼은 749개의 서로 다른 품목으로 구성됨. 모델의 일반화 성능 향상을 위해 표준화된 식품 유형으로 분류

- 이는 모델이 749개의 개별 제품명을 각각 암기하는 과적합(Overfitting)을 방지하고, '견과류', '과자류' 등 상위 그룹의 공통된 특징을 학습하여 처음 보는 유사 제품에도 예측 성능을 발휘할 수 있게 하기 위함.

○ 식품안전정보원에서 제공받은 식품유형 분류표를 활용 한 1차 분류

- 식품유형 분류표는 식품공전 등을 출처로 513개 식품에 대한 39개의 1차분류와 7개의 2차분류로 구성. 식약처 의견에 따라 분류 간, 39개 1차분류 활용(아래 표[] 참고)

	분류명		분류명		분류명		분류명
1	과자류, 빵류 또는 떡류	11	특수의료용도식품	21	동물성가공식품류	31	향신식물
2	빙과류	12	장류	22	즉석식품류	32	기타 식물류
3	코코아가공품류 또는 초콜릿류	13	조미식품	23	기타식품류	33	식육류
4	당류	14	절임류 또는 조림류	24	곡류	34	우유류
5	잼류	15	주류	25	서류	35	알류
6	두부류 또는 묵류	16	농산가공식품류	26	두류	36	영양성분(건강기능식품 공전 수록)
7	식용유지류	17	식육가공품류 및 포장육	27	견과 종실류	37	기능성원료(건강기능식품 공전 수록)
8	면류	18	알가공품류	28	과일류	38	건강기능식품(제품)
9	음료류	19	유가공품류	29	채소류	39	식품첨가물
10	특수영양식품	20	수산가공식품류	30	버섯류		

[표 5] 식정원 식품유형 분류표의 1차분류 39개

- 1차 분류 후, 식품분류표 요청 당시 데이터와 현재 데이터셋의 차이에서 미분류 데이터 발생

- 매칭된 행 수: 166,758 (98.02%)
- 미 매칭 행 수: 3,374 (1.89%)

- 미 매칭 데이터의 품목명 중 '압몰수 임의 품목' 값 총 57개의 행 식별 후 제거 (아래 표[] 참고)

구분	수량(건)	비율(%)
전체 데이터 행 수	170,189	-
'압몰수 임의 품목' 값 제거후	170,132	-
매칭된 행 수	166,758	98.02
미 매칭 행 수	3,374	1.98

[표 6] 1차분류 최종 결과요약표

○ Gemini AI를 활용한 2차 분류

- 분류 원칙 및 기준

  • 식정원 제공 식품유형 분류표의 분류 체계를 기반으로 함

  • 원본 분류 체계와의 일관성 유지를 최우선 원칙으로 설정

- 1단계: 기준표 패턴 분석 및 규칙 도출

  • 가공 여부에 따른 분류: 동일 원물이라도 '건조'와 '냉동'의 분류가 다름을 식별

  • '건조' 포함 품목 → 원물 유형이 아닌 농산가공식품류로 분류하는 규칙 확립 (예: 무말랭이)

  • '냉동' 포함 품목 → 가공식품이 아닌 원재료 유형 유지를 원칙으로 함 (예: 냉동딸기 → 과일류)

- 2단계: 규칙 기반 패턴화 분류 적용

  • 도출된 규칙을 일괄 적용

  • 단순 건조 농산물(귀리건조, 무청건조, 호박건조 등 38종)을 농산가공식품류로 일괄 이동

  • 약용으로 주로 쓰이는 열매류(구기자, 오미자, 산수유)는 기준표에 의거 과일류로 예외 적용

- 3단계: 모호 품목에 대한 특성 기반 세부 분류

  • 기준표에 명시되지 않은 약용 식물류의 세분화

• 풀/뿌리류(칡, 우슬, 엉겅퀴 등) → 방향성 및 섭취 특성 고려 향신식물로 분류

• 나무/껍질류(엄나무, 비술나무, 왕느릅나무 등) → 기타 식물류로 분류

- 4단계: 특수 목적 식품 및 누락 검증

• 기능성원료 및 특수용도식품은 별도 공전 기준에 따라 정밀 분류

• '영·유아용 특수조제식품' → 특수의료용도식품으로 정확히 매칭

• 최종 전수 검사를 통해 누락 품목(맥문동건조 등) 재분류 완료

- 제미나이를 활용한 2차 분류 과정 요약은 다음과 같음(아래 표[] 참고)

단계	분류 방법	핵심 내용
1단계	기준 패턴 분석	'건조' vs '냉동'의 분류 차이 식별
2단계	규칙 기반 분류	건조 농산물의 '농산가공식품류' 일괄 적용
3단계	특성 기반 분류	약용 식물의 부위별(풀/나무) 세부 분류
4단계	정밀 검증	특수식품 매칭 및 누락 품목 최종 확인

[표 7] 제미나이 활용 2차 분류과정 요약

○ 주요 분류 사례

- 농산가공식품류 분류 (패턴 적용)

• 귀리건조, 표고버섯건조, 무(뿌리)건조, 호박씨건조 등

• 원재료명에 '건조'가 포함된 경우, 원물 카테고리(곡류, 버섯류 등)에서 농산가공식품류로 변경

- 향신식물 vs 기타 식물류 구분 (특성 적용)

• 향신식물: 칡, 우슬, 엉겅퀴, 민들레, 질경이 등 (주로 풀, 뿌리 활용 식물)

• 기타 식물류: 엄나무, 비술나무, 찔레나무, 겨우살이 등 (주로 목재, 수피 활용 식물)

- 예외 규칙 적용 사례

- 오미자, 구기자, 산수유: 약용으로도 쓰이나 기준표상 본질적인 특성을 인정하여 과일류로 분류
- 옥수수냉동, 딸기냉동: '냉동'은 단순 저장 처리로 보아 각각 곡류, 과일류 원재료 분류 유지

○ 총 749개의 품목명, 전체 170,132건의 데이터에 대해 100% 분류. 최종 카테고리 수는 44개. 이는 모델의 일반화 성능 향상과 식품 유형별 특성 파악에 기여 할 것으로 기대 (아래 표[] 참고)

구분	수량
전체 데이터 행수	170,132
분류 완료 행수	170,132 (100%)
최종 카테고리 수	44개

[표 8] 식품 유형 분류 결과

□ LIMS 데이터 결측치 처리

○ LIMS(통합실험실정보관리시스템) 데이터 다수의 컬럼에서 결측치 발견 (아래 표[] 참고)

○ 데이터 품질을 높이기 위해, 결측률이 높은 컬럼 일괄 삭제.

○ 이 과정에서 분석에 반드시 필요한 컬럼만을 남긴 후, 결측값이 일부 존재하는 품목명(결측치 약 0.01%)의 경우 결측치 존재 행만 제거

컬럼명	결측치 수	결측률	처리 방법
검사목적명	0건	0%	-
품목명	0건	0%	-
원산지국가코드	167,655	98.54%	컬럼 제거
검사대상종류	36,178건	21.26%	컬럼 제거
시료상태명	85,025건	49.98%	칼럼 제거

[표 9] LIMS 데이터 결측 및 처리 현황

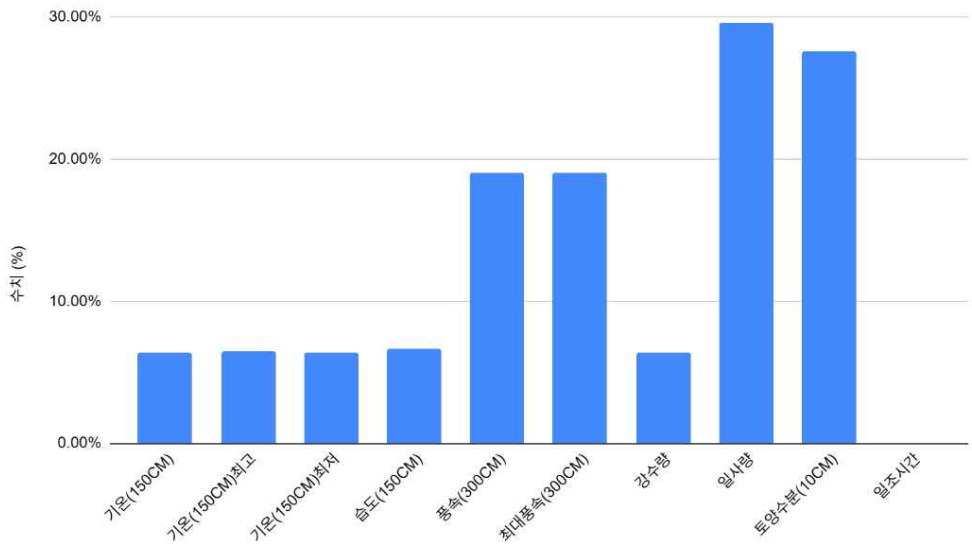
□ 기후 데이터 결측치 처리

○ 결측률 최고 29.5%(일사량)부터 최저 6.5%(기온(150cm))까지, 일조시간(결측률0%)

칼럼을 제외한 다른 칼럼 다수 결측치 존재 (아래 표[],그림[] 참고)

기상 항목	결측비율 (%)
일조시간	0%
기온(150CM)	6.42%
기온(150CM)최고	6.43%
기온(150CM)최저	6.42%
습도(150CM)	6.65%
풍속(300CM)	19.06%
최대풍속(300CM)	19.07%
강수량	6.42%
일사량	29.55%
토양수분(10CM)	27.57%

[표 10] 기후항목 별 결측비율



[그림 3] 기상항목 별 결측비율 시각화

□ 시계열 보간

○ 기후 변수(온도, 강수량, 습도 등)는 결측치 행을 제거하면 데이터 손실이 크므로 (약 29%), 시계열적 특성을 고려해 보간 처리를 수행.

○ 변수별 60일 시계열 그룹화, 후방채우기로 미래 값으로 채우기, 전방채우기로 과거 값으로 채우기, 양끝 결측을 0으로 처리, 결측치 보간 100% 성공. (아래 표[] 참고)

단계	방법	설명	예시
1단계	그룹화	변수별 60일 시계열 그룹화	평균기온_00~59,강수량_00~59
2단계	후방채우기	그룹별로 결측치 미래 값으로 채우기	[NaN, 20, 21] → [20, 20, 21]
3단계	전방채우기	과거 값으로 채우기	[18, 19, NaN] → [18, 19, 19]
4단계	0값 처리	양끝 결측은 0으로 처리	[NaN, NaN, 20] → [0, 0, 20]

[표 11] 시계열 보간 프로세스 요약표

○ 이는 시계열 보간 프로세스가 모든 결측치를 성공적으로 처리했음을 의미하며, 데이터 품질이 크게 향상되었음을 보여줌 (아래 표[] 참고)

기후 데이터 보간 전	기후 데이터 보간 후
최초 평균 12.7%의 칼럼별 결측치	변수별 시계열 그룹화 및 결측치 기준 전후방 보간으로 -> 보간률 100%

[표 12] 기후데이터 보간 전 후 결측치 현황

1.4 다운사이징

□ 클래스 불균형 현황

○ 적합(0)은 169,323건으로 99.52%를 차지하는 다수 클래스이며, 부적합(1)은 809건으로 0.47%를 차지하는 소수 클래스.

○ 이는 극심한 클래스 불균형을 보여주며, 모델이 다수 클래스에 편향되어 학습 될 가능성이 높음. 이러한 불균형은 소수 클래스인 부적합의 예측 성능을 저하시킬 수 있어, 다운사이징 등의 불균형 해소 기법이 필요

○ 아래는 기상 결측치 보간 등의 전처리가 완료된 데이터셋에 y값(종속변수)인 JDGMNT_WORD_NAME_encoded 의 분포 현황을 정리한 표 (아래 표[] 참고)

클래스	건수	비율	특성
적합 (0)	169,323건	99.52%	다수 클래스
부적합 (1)	809건	0.47%	소수 클래스
합계	170,132건	100%	극심한 불균형

[표 13] 종속변수 분포 현황

□ 클래스 불균형 문제점

○ 모델이 다수 클래스(적합)에 편향되어 학습

○ 소수 클래스(부적합) 예측 성능 저하

○ 정확도는 높지만 실제 부적합 검출률 낮음

○ 클래스 불균형을 완화하기 위한 다운사이징 적용

□ 다운사이징 전략

○ 검사목적(수거검사 등)과 식품분류(국류,)의 모든 조합에 대해 부적합률을 계산하고, 0%인 조합을 제거하여 클래스 불균형을 완화함.

- 전략 근거

  • 과거 이력상 부적합이 한 건도 없는 조합은 향후 부적합 가능성 매우 낮음

  • 해당 조합 제거로 모델의 실용성에 문제없음

  • 다수 클래스 데이터 감소로 클래스 불균형 완화

□ 부적합률 0% 조합 식별

○ 검사목적(9개 류종)과 식품분류(44개 종류)의 조합별로 부적합률을 계산한 결과, 검사명령검사와 농산가공식품류, 기타와 건강기능식품(제품) 등 총 91개의 조합에서 부적합률이 0%로 나타남

○ 이러한 조합들은 과거 이력상 부적합이 한 건도 없어 향후 부적합 가능성이 매우 낮다고 판단되어 제거 (아래 표[] 참고)

검사 목적 (INSPCT_PURPS_NAME)	1차 식품 분류 (세부)	판정 결과 (JDGMNT_WORD_NAME_encoded)
검사명령	농산가공식품류	0.0
기타	건강기능식품(제품)	0.0
기타	견과 종실류	0.0
기타	곡류	0.0
기타	당류	0.0
품질검사	농산가공식품류	0.0
품질검사	장류	0.0
품질검사	조미식품	0.0
품질검사	코코아가공품류 또는 초콜릿류	0.0
허가.인증 신청 및 신고 검사	건강기능식품(제품)	0.0
...	...	...

[표 14] 다운사이징 과정에서 제거된 부적합률 0% 조합의 예시 정리 표

□ 다운사이징 실행 결과

○ 데이터 건수 170,132건에서 158,698건으로 11,434건(-6.72%) 감소.

○ 적합(0) 클래스 169,323건에서 157,889건으로 11,434건(-6.75%) 감소

○ 부적합(1) 클래스 809건으로 변화 없음

○ 부적합 비율 0.47%에서 0.50%로 약 0.03% 증가 (아래 표[] 참고)

구분	다운사이징 전	다운사이징 후	변화
데이터 건수	170,132건	158,698건	-6.72%
적합 (0)	169,323건	157,889건	-6.64%
부적합 (1)	3,953건	3,953건	변화 없음
부적합 비율	0.4755%	0.5097%	+0.03%p

[표 15] 다운사이징 실행 결과

□ 데이터셋 정제 과정 전체 요약

○ 불필요 데이터 제거로 데이터 수 443,824건에서 170,189건으로 감소

○ 식품유형 분류로 749개 품목을 44개 카테고리로 표준화

해당 과정에서 압몰수 임의 품목이라는 식별 불가 값 식별후 제거

170,189건 -> 170,132건

○ LIMS 데이터의 핵심 2개 변수(검사유형, 1차식품분류) 제외 모두 제거, 기상 데이터는 시계열 보간을 적용

○ 다운사이징으로 데이터 수 170,132건 -> 158,698건으로 감소

○ 다운사이징을 완료한 최종 데이터셋은 총 158,698건의 데이터와 604개의 컬럼으로 구성됨 (아래 표[] 참고)

단계	작업 내용	결과
1단계	분석 대상데이터 범위 선정	443,824건 → 170,189건
2단계	식품유형 분류 (식품공전 기준)	749개 품목 → 44개 카테고리
		압몰수 임의 품목 값 제거 170,189건 -> 170,132건
3단계	결측치 처리	LIMS: 검사유형, 1차식품분류 기상: 시계열 보간
4단계	다운사이징 (클래스 불균형 해소)	데이터 행 수: 170,189건 → 158,698건
		데이터 칼럼 수: 611개 -> 604개

[표 16] 전처리 과정 단계별 요약표

○ 독립변수(X)로 활용 될 수 있는 '검사목적명', '1차 식품세부 분류' 2개 칼럼과 기상 변수의 60일 시계열 데이터로 구성된 600개의 기상 데이터 컬럼 포함

○ 종속변수(y)로 활용 될 수 있는 '결과값', '부/적합 이진분류' 총 2개 컬럼 (아래 표[] 참고)

구분	컬럼 수(개)	설명
기상 데이터	600	10개 기상 변수 × 과거 60일 시계열 데이터
LIMS 데이터	2(종속변수)	결과값, 부/적합 이진분류
	2	검사목적명, 1차 식품세부 분류
총 컬럼 수	604	독립변수 + 종속변수

[표 17] 생성한 데이터 셋 요약표

2. 탐색적 데이터 분석 (EDA)

□ 다운사이징을 완료한 데이터를 대상으로 주요 변수들의 분포와 관계를 분석

○ 전체 데이터 중 부/적합 값 분포

- 적합: 157,889 (99.4902%)
- 부적합: 809 (0.5098%)

○ 식품 유형별 부적합률

- '영양성분(건강기능식품 공전 수록)' 카테고리가 가장 높은 부적합률(50.00%) 기록
- '식용유지류'(9.5%), '잼류'(8.6%)가 5% 이상의 높은 부적합률
- '농산가공식품류'는 79,232건으로 많은 데이터를 포함하나 부적합률은 0.2%
- 대부분의 식품 유형이 5% 미만의 부적합률을 보임 (아래 표[] 참고)

식품 유형	전체 건수	부적합 건수	부적합률(%)
영양성분(건강기능식품 공전 수록)	4	2	50.0000
식용유지류	21	2	9.5238
잼류	23	2	8.6957
곡류	1877	26	1.3852
장류	9493	128	1.3484

음료류	842	7	0.8314
과자류, 빵류 또는 떡류	54684	417	0.7626
채소류	790	6	0.7595
코코아가공품류 또는 초콜릿류	312	2	0.6410
조미식품	3,739	22	0.5884
건강기능식품(제품)	2,693	15	0.5570
특수영양식품	182	1	0.5495
유가공품류	784	4	0.5102
두류	1,669	6	0.3595
식육가공품류 및 포장육	472	1	0.2119
농산가공식품류	79,232	165	0.2082
과일류	537	1	0.1862
기타식품류	1,344	2	0.1488

[표 18] 식품 유형 별 부적합률의 수와 비율

○ 검사 목적에 따른 부적합률 분석을 통해 각 검사 유형별로 아플라톡신 부적합 발생 패턴을 파악

- 제조.수입품목허가(신고)용검사는 6%로 가장 높은 부적합률
- 자가품질위탁검사는 총 129,135건으로 압도적 최다 검사 수행, 부적합률은 약 0.45%로 가장 낮음
- 기타(약 0.80%), 수거검사(약 0.77%) 순으로 중간 수준의 부적합률 보임 (아래 표 [] 참고)

검사 목적	전체 건수	부적합 건수	부적합률(%)
제조.수입품목허가 (신고)용검사	99	6	6.0606
기타	4,148	33	0.7956
수거검사	25,316	194	0.7663
자가품질위탁검사	129,135	576	0.4460

[표 19] 검사목적 별 부적합률의 수와 비율

□ EDA 주요 발견 사항

○ 식품 유형별 부적합

- 특정 품목 위험도: '영양성분(건강기능식품)'(50%), '식용유지류'(9.5%), '잼류'(8.7%) 등 특정 품목의 부적합률이 현저히 높음. 모니터링 강화 필요.
- 대량 품목 저위험도: 최다 빈도의 '농산가공식품류'(약 7.9만 건)는 0.2%의 낮은 부적합률을 보임. 데이터 불균형 심화 요인.
- 전반적 경향: 대부분 식품 유형의 부적합률이 1% 미만으로, 오염이 특정 고위험군에 집중되는 경향을 보임

○ 검사 유형별 부적합 현황

- 고위험군 식별: '제조·수입품목허가(신고)용 검사'의 부적합률이 6.06%로 가장 높음. 허가 단계에서의 집중 관리 필요.
- 관리 안정성 확인: '자가품질위탁검사'는 전체의 대다수(약 12.9만 건)를 차지하며 0.45%의 낮은 부적합률을 기록, 비교적 안정적인 관리 상태를 보임.

○ 종합 시사점 및 향후 계획

- 타겟 관리: 제조/수입 허가 단계 및 고위험 식품군(영양성분, 식용유지류 등)에 대한 선별적 집중 관리 필요.
- 모델링 전략: 심각한 클래스 불균형 해결을 위한 데이터 오버샘플링 등 특화된 모델링 기법 적용 필수

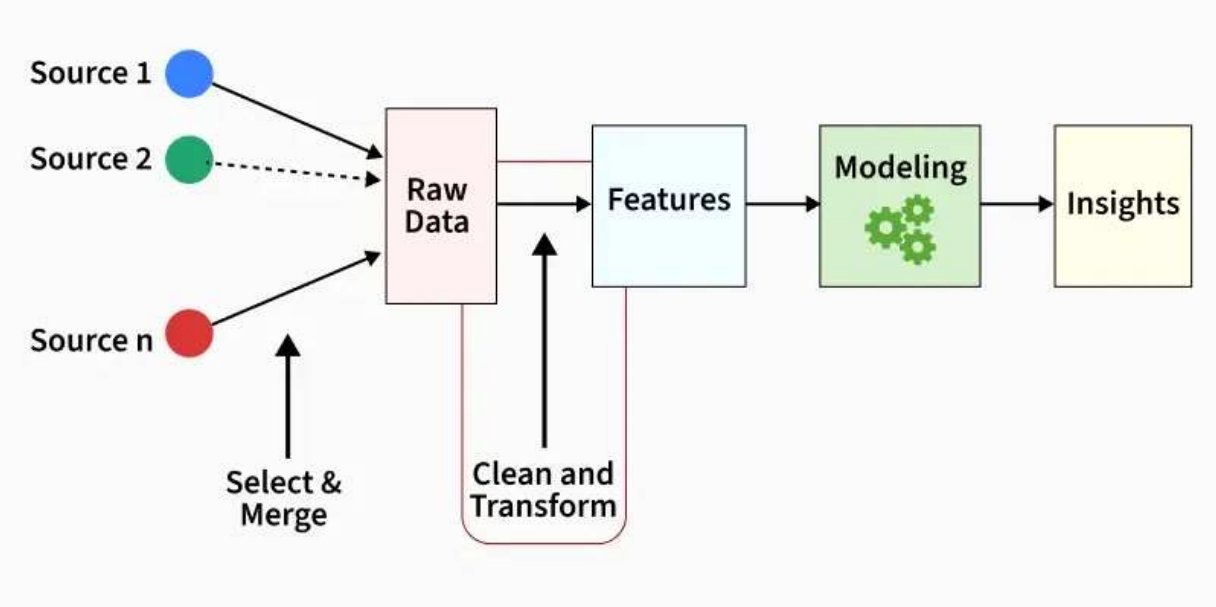
3. 특성공학

□ 특성공학 개요

○ 특성공학(Feature Engineering)은 원본 데이터로부터 예측 모델의 성능을 높이기 위해 새로운 입력 특성(변수)을 생성하거나 기존 특성을 변환·조합하는 데이터 전처리 과정 (아래 그림[] 참고)

○ 특성공학은 도메인 지식, 통계 분석, 외부 레퍼런스 등을 바탕으로 데이터에 포함되지 않은 유용한 정보를 추출함으로써 머신러닝 모델이 패턴을 더 잘 학습할 수 있도록 함

○ 본 연구에서는 아플라톡신 예측 문제에 있어 기상 데이터의 시계열 특성을 기초로 새로운 변수(특성)를 설계하고 실험



[그림 4] 특성공학(Feature Engineering) 개요 시각화

□ 모델 설계

○ 모델 학습 및 평가

- 알고리즘: 하이브리드 딥러닝 모델(최종 예측 모델과 동일)
  - LSTM과 Attention 메커니즘을 결합하여 시계열 데이터의 장기적인 의존성과 핵심 정보 추출 능력을 극대화
- 하이퍼파라미터: 예측모델 개발 부문에서 서술(최종 예측 모델과 동일)
- 평가 지표: Accuracy, Precision, Recall, F1-Score, AP Score, ROC-AUC 등예측모

델 개발 부문에서 서술(최종 예측 모델과 동일)

□ 실험 과정

○ 식정원에서 제공된 아플라톡신 발생에 대한 연구들을 레퍼런스로, 다음과 같은 3개의 핵심 특성을 생성 이후 원본데이터와 비교 학습 실험

- 독소 생성 최적 온도 일수[1)]

  • 데이터 행의 과거 7일치 기온 컬럼 중 '(25°C ≤ 일별 기온 ≤ 35°C)'이 성립하는 일수의 총합을 계산하여 새 변수로 생성

- 저습도 일수[2)]

  • 데이터 행의 과거 7일치 습도 컬럼 중, 각 일별 습도가 60% 미만인 날에 대해 True/False 마스킹 후 7일 간 '일별 습도 < 60%' 조건을 만족하는 일수의 합을 계산하여 변수로 생성

- 연속 무강수 일수[3)]

  • 데이터 행의 과거 7일치 강수량 컬럼 중, 각 일별 강수량이 0인 날을 True/False로 변환한 후, 7일 연속 구간 내 가장 긴 연속 True 구간의 길이를 변수로 생성하였으며 즉, window 내에서 강수량 0이 연속적인 최장기간의 일수

○ 실험 결과

- 레퍼런스 기반 특성공학 적용 결과, 모든 성능 지표에서 성능개선, 특히 Precision, Recall, F1-Score가 약 40% 향상

  • 도메인 지식 기반 3개 특성 추가만으로 유의미한 성능 개선 (아래 표[] 참고)

1) FAO, Worldwide Regulations for Mycotoxins in Food and Feed, 2001, p.17.
2) 강릉원주대학교, "기후변화 시뮬레이션을 통한 위해인자 영향분석 및 관리방안", 식품의약품안전평가원, 2014.
3) Bowen, K.L., Hagan, A.K., "Temperature and Moisture Conditions That Affect Aflatoxin Contamination of Peanuts", Peanut Science, Vol.42, No.2, 2015.

지표	특성공학 후 개선도
ACCURACY	+0.5717%
PRECISION	+40.6789%
RECALL	+39.5349%
F1	+40.6405%
AP_SCORE	+15.1800%
ROC_AUC	+10.3222%

[표 20] 특성변수공학 실험 결과

□ 추가 특성공학

○ 시계열 데이터 기간 선정

- 추가적으로, 60일치 기상 전체 데이터 셋 중 10일 단위로 10~60일치 데이터의 성능을 비교한 결과, 50일치 데이터에서 가장 높은 성능으로 50일치 데이터로 최종 기상 데이터 선정

○ Target mean

- 식품유형과 검사종류를 바탕으로 Target mean encoding을 적용

  • Target Mean 방법은 범주형 변수의 유형별로 종속변수의 평균을(Target mean) 구해 수치형으로 전환(encoding)하여 예측 성능을 높이는 것

  • 본 연구의 전체 데이터 크기는 158,698개로 과거 데이터의 개수가 빅데이터 규모로 예측할 자료의 분포가 과거 데이터와 같다는 가정을 전제로 해도 무방함

  • 추가 및 수정된 특성변수 현황은 아래 표[] 와 같음

	추가 및 수정된 변수	설명
1	독소 생성 최적 온도 일수	과거 7일 25~35°C 범위 일수
2	저습도 일수	과거 7일 습도 60% 미만 일수
3	연속 무강수 일수	과거 7일무강수 연속일수
4	50일치 10개 기상변수 (0~49)	기 60일치 기후변수 -> 50일치로 축소
5	Target Mean	식품유형과 검사종류 별 부적합률의 평균값

[표 21] 추가 및 수정된 변수 현황표

4. 아플라톡신 부적합 예측 모델링용 최종 데이터

1.1 분석대상 최종 데이터 생성 개요

○ 식품의약품안전처 아플라톡신 LIMS 데이터와 기상 데이터를 수집 및 병합 후 데이터 정제, 특성공학, 예측성능 향상을 위한 다운사이징(부적합률 상승) 등 수행

□ 데이터 구조

○ 관측치(observation) 개수: 158,698개

○ 총 변수 개수: 508개 (아래 표[] 참고)

대분류	세부 항목	변수 개수 (개)	주요 내용
데이터 개요	총 관측치 (Observations)	158,698	LIMS 데이터 + 기상 데이터 병합
	총 변수 (Variables)	508	X(입력변수) 506개 + Y(출력변수) 2개

[표 22] 최종 모델링용 데이터 개요

○ 입력변수(X, Input) 구성 - 총 506개

- 기후 시계열 정보 (500개)

  • afp_00, afp_0 ~ tmprt_150_48, tmprt_150_49 등

- LIMS 정보 (2개)

- 검사 목적명(INSPCT_PURPS_NAME)
- 1차 식품 분류

- 추가한 특성 정보 (4개)

- 독소 생성 최적 온도 일수: 검사시점 기준 과거 7일간 독소 생성에 가장 적합한 온도(25°C~35°C) 범위에 해당했던 날의 총 일수
- 저습도 일수: 검사시점 기준 과거 7일간 습도가 60% 미만으로 건조했던 날의 총일수
- 연속 무강수 일수: 검사시점 기준 과거 7일간 비가 오지 않고(강수량 0) 연속적으로 이어진 날의 최대 기간(일수)
- Target mean: 식품유형과 검사종류 별 부적합률의 평균값

○ 출력변수(Y, Output) 구성 - 총 2개

- 결과값 (검출결과값)
- JDGMNT_WORD_NAME_encoded (아플라톡신 부/적합 여부 이진 인코딩)

- 아래는 최종 데이터셋 X,Y 현황을 정리한 표 (아래 표[] 참고)

구분	변수	내용
입력변수(X) 구성 (총 506개)	500개	① 기후 시계열 정보: afp_00, afp_0, tmprt_150_48, tmprt_150_49 등
	2개	② LIMS 정보: 검사 목적명(INSPCT_PURPS_NAME), 1차 식품 분류
	4개	③ 추가 생성 특성: 독소 생성 최적 온도 일수, 저습도 일수, 연속 무강수 일수, target mean
출력변수(Y) 구성 (총 2개)	1개	① 결과값(검출결과): 실험을 통해 측정된 최종 검출 결과 값
	1개	② JDGMNT_WORD_NAME_encoded: 아플라톡신(Aflatoxin) 결과 부/적합 이진 인코딩 값

[표 23] 최종 모델링용 데이터 X.Y 구성

II. 예측모델 개발 부문

1. 서론

1.1 연구 배경

○ 전 세계적으로 기후 변화, 환경 오염, 그리고 복잡해지는 글로벌 식품 공급망으로 인해 식품 위해 요소의 발생 가능성과 불확실성이 증가

- 특히, 곰팡이 독소인 아플라톡신(Aflatoxin)과 같이 기후 환경 변화에 민감하게 반응하는 위해 요소는 곡물 및 식품 안전에 심각한 위협 발생

○ 현재 사후 대응 중심의 전통적인 식품 안전 관리 체계는 한계를 보이며, 식품 사슬 전 주기에 걸쳐 위해 요소를 선제적으로 파악하고 리스크를 관리할 수 있는 사전 예방적(Proactive) 체계 구축의 필요성이 대두

○ 이는 글로벌 정책 기조에도 부합하는 것으로, 증거 기반의 예측 기술을 활용하여 위해 발생 가능성을 미리 식별하고, 이에 기반한 예방 정책을 수립하는 것이 식품 안전 관리의 핵심 목표

- 따라서 국내 식품 안전 관리 기관 역시 향후 구축될 식품 위해 예측 시스템의 기반을 마련하기 위해 우선순위 위해 요소에 대한 고도화된 예측 모델 개발 연구가 시급히 요구

1.2 연구 목적

□ 국내·외 식품 검사 및 환경 데이터를 통합적으로 활용하여 우선순위 위해 요소(아플라톡신)의 발생을 예측하는 고성능 예측 모델을 개발

□ 구체적인 연구 목적은 다음과 같음

○ 시계열(Time Series) 데이터와 카테고리(Categorical) 데이터의 복합적인 특성을 모두 반영할 수 있는 하이브리드 딥러닝 모델(Hybrid Deep Learning Model)을 설계하고 구현

○ 부적합 데이터 비율이 매우 낮은 극심한 데이터 불균형(Severe Data Imbalance) 문제를 효과적으로 해결할 수 있는 데이터 전처리 및 학습 기법을 탐색하고 적용하여 모델의 실효성을 확보

○ 개발된 모델의 예측 성능을 정밀도(Precision), 재현율(Recall), F1-score, 그리고 불

균형 데이터 평가에 필수적인 AP(Average Precision) 등 다각적인 지표를 통해 체계적으로 검증하여, 향후 국가 식품위해예측 시스템 구축의 기술적 기반을 마련하는 것이 목표

2. 데이터 설명

2.1 데이터 개요

□ 식품의약품안전처의 LIMS(Laboratory Information Management System) 데이터

○ 핵심 데이터는 식품의약품안전처의 LIMS(Laboratory Information Management System) 데이터 내의 아플라톡신 검사 결과

- 특정 기간 동안의 식품 검사 샘플에 대한 적합/부적합 여부를 포함하고 있으며, 이는 본 연구의 종속 변수(Target Variable)인 부적합 발생 여부(Non-conformity)를 정의하는 데 사용

○ 데이터의 초기 특성은 다음과 같음

- 종속 변수 (부적합): 이진 분류(Binary Classification) 형태(적합/부적합).

  • 데이터 불균형: 최초 부적합 데이터의 비율은 약 0.51% 이하로, 극심한 불균형 상태로 이는 모델 학습 시 부적합 사례를 거의 학습하지 못하고, 대부분의 예측을 '적합'으로 치우치게 만드는 근본적인 어려움을 야기함

□ 외부 기후 데이터

○ 식약처의 검사 결과의 원인 시점인 검사 시점 이전의 기온, 강수량, 일조량 등 시간 정보(Time Series)는 수거검사의 제품 종류, 검사종류, 검사 기관 등의 카테고리 정보(Categorical)와 연계되어 구성.

□ 전체 데이터 구성

○ 158,698개의 관측치와 506개의 X(독립변수)와 2개의 Y(종속변수)로 구성

○ 부적합률 0.5098% 으로 이루어진 극심한 불균형데이터

2.2 카테고리 데이터 특성 및 전처리

○ X(독립변수) 중 카테고리 데이터는 주로 식품의 속성(Attributes)정보로 예를 들어, 식품 종류, 검사 유형 정보 등이 이에 해당

- 특성:

  • 일부 카테고리 변수는 높은 카디널리티(High Cardinality)를 가질 수 있으며 이러한 변수들은 수치적인 연속성이 없기 때문에 모델에 직접 투입될 수 없음

- 전처리:

  • 카디널리티 관리: 빈도수가 낮은 카테고리는 '기타'로 통합(Grouping)하여 데이터의 희소성을 방지

  • '1차 식품 분류' 변수에서 100개 이하 값을 식별후 '기타' 값으로 통합 (아래 표[] 참고)

'기타'로 통합(Grouping)

이전

	1차 식품 분류	총 개수	0	1
0	건강기능식품(제품)	2693	2678	15
1	곡류	1877	1851	26
2	과일류	537	536	1
3	과자류, 빵류 또는 떡류	54684	54267	417
4	기타식품류	1344	1342	2
5	농산가공식품류	79232	79067	165
6	두류	1669	1663	6
7	식용유지류	21	19	2
8	식육가공품류 및 포장육	472	471	1
9	영양성분(건강기능식품 공전 수록)	4	2	2
10	유가공품류	784	780	4
11	음료류	842	835	7
12	장류	9493	9365	128
13	잼류	23	21	2
14	조미식품	3739	3717	22
15	채소류	790	784	6
16	코코아가공품류 또는 초콜릿류	312	310	2
17	특수영양식품	182	181	1

[그림 5] 통합 전 식품 분류 변수 현황

이후

	1차 식품 분류	개수
0	농산가공식품류	79232
1	과자류, 빵류 또는 떡류	54684
2	장류	9493
3	조미식품	3739
4	건강기능식품(제품)	2693
5	곡류	1877
6	두류	1669
7	기타식품류	1344
8	음료류	842
9	채소류	790
10	유가공품류	784
11	과일류	537
12	식육가공품류 및 포장육	472
13	코코아가공품류 또는 초콜릿류	312
14	특수영양식품	182
15	기타	48

[그림 6] 통합 후 식품 분류 변수 현황

[표 24] 식품분류 변수의 카디널리티 관리 전후 현황

- ‘검사유형’ 변수는 고유값이 많지 않아 정보손실 우려로 통합하지 않음 (아래 그림[] 참고)

	INSPCT_PURPS_NAME	개수
0	자가품질위탁검사	129135
1	수거검사	25316
2	기타	4148
3	제조.수입품목허가(신고)용검사	99

[그림 7] 검사유형 칼럼 현황

- 원-핫 인코딩(One-Hot Encoding, OHE): 카디널리티가 낮은 범주형 변수에는 OHE를 적용하여 모델이 각 범주를 독립적인 특성으로 인식

2.3 타임 시리즈 데이터 특성 및 전처리

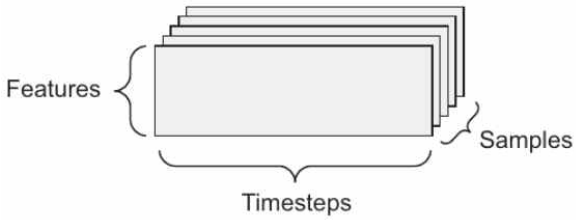
○ 타임 시리즈 데이터는 수거 시점과 부적합 발생 시점의 시간적 흐름 및 환경 요인과 관련된 특성으로 구성

○ 특성:

- 시간적 의존성: 아플라톡신 발생은 특정 계절, 연도별 트렌드, 또는 특정 시점 이전의 환경 조건(온도, 습도 등)에 영향을 받음
- 순서 정보의 중요성: 모델이 현재 시점의 예측을 위해 과거의 데이터 패턴(예: 지난 몇 주간의 부적합 빈도)을 학습
  - 본 연구에서는 부적합의 극심한 불균형성으로 빈도를 반영하지 못함

○ 전처리:

- 시퀀스 구성(Sequencing/Windowing): 단일 시점의 데이터가 아닌, 특정 기간(50일)동안의 과거 데이터를 묶어 시퀀스(Sequence) 형태로 구성
  - LSTM 모델의 입력 형태로 필수적
  - 스케일링(Scaling): 기온, 습도 등 수치형 시계열 데이터는 모델 학습의 안정성과 수렴 속도 향상을 위해 standardScaling 적용
  - 50일(TImesteps)동안의 10개 features(기온, 강수량 등)의 3차원 데이터 구조 (아래 그림[] 참고)



[그림 8] 타임시리즈 데이터 형태

3. 모델 설계

○ 본 연구의 핵심은 이질적인 데이터 특성(시계열 및 카테고리)을 모두 효과적으로 처리하기 위한 하이브리드 딥러닝 모델의 설계

- LSTM과 Attention 메커니즘을 결합하여 시계열 데이터의 장기적인 의존성과 핵심 정보 추출 능력을 극대화람

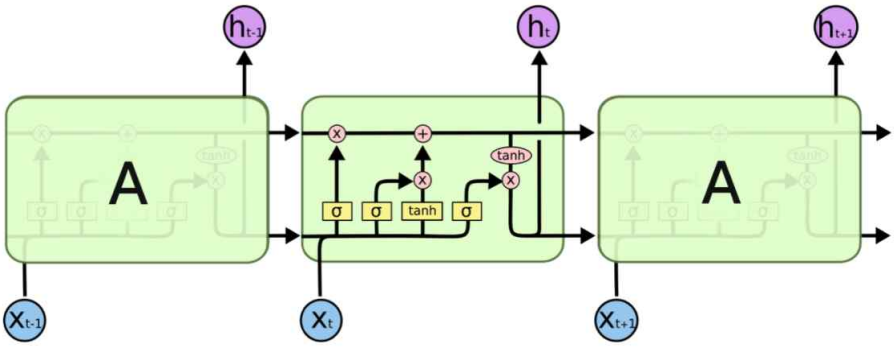
3.1 LSTM 모델

○ LSTM(Long Short-Term Memory)은 순환 신경망(RNN)의 한 종류로, 기존 RNN이 가지는 장기 의존성(Long-Term Dependency) 문제를 해결하기 위해 고안

- 역할: 장기 패턴 학습: 타임 시리즈 데이터 시퀀스 내에서 50일에 걸친 기후 변화와 같은 장기적인 패턴과 의존성을 효과적으로 포착

○ 게이트 메커니즘: 입력 게이트(Input Gate), 망각 게이트(Forget Gate), 출력 게이트(Output Gate)를 통해 셀 상태(Cell State)를 조절

- 불필요한 과거 정보를 지우고 중요한 정보를 다음 단계로 전달하여 예측 성능을 높이기 위해 RNN 구조에서 아래 그림 []와 같은 Cell State와 세 가지 주요 Gate(forget, input, output)가 존재



[그림 9] LSTM Cell State와 세 가지 주요 Gate 예시 이미지

3.2 Attention 모델

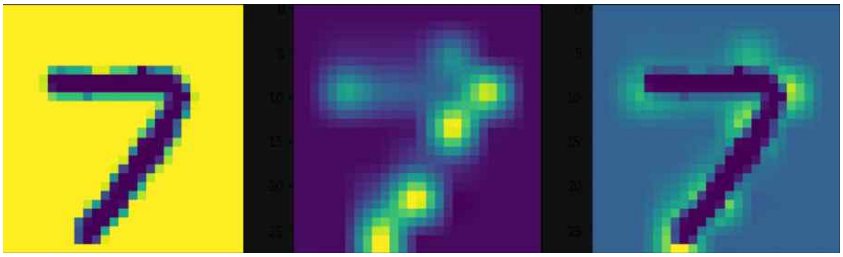
○ Attention 메커니즘은 LSTM 레이어의 출력 시퀀스에 적용되어, 모델이 최종 예측을 수행할 때 시퀀스 내의 가장 중요한 부분(Relevant Time Steps)에 가중치를 부여하여 예측 성능을 높임

- 역할: 정보 선택적 집중

  • 예를 들어, 아플라톡신은 수확 직전의 기후 조건에 민감할 수 있으며 Attention 메커니즘은 시퀀스 내의 수많은 과거 데이터 중 결과에 가장 큰 영향을 미친 특정 시점의 데이터에 높은 가중치를 부여하여 집중도를 향상

- 해석 가능성 제공: 어떤 시점의 데이터가 예측에 중요했는지 가중치를 통해 시각적으로 확인할 수 있어, 모델의 예측 근거에 대한 해석 가능성(Interpretability)을 일부 제공

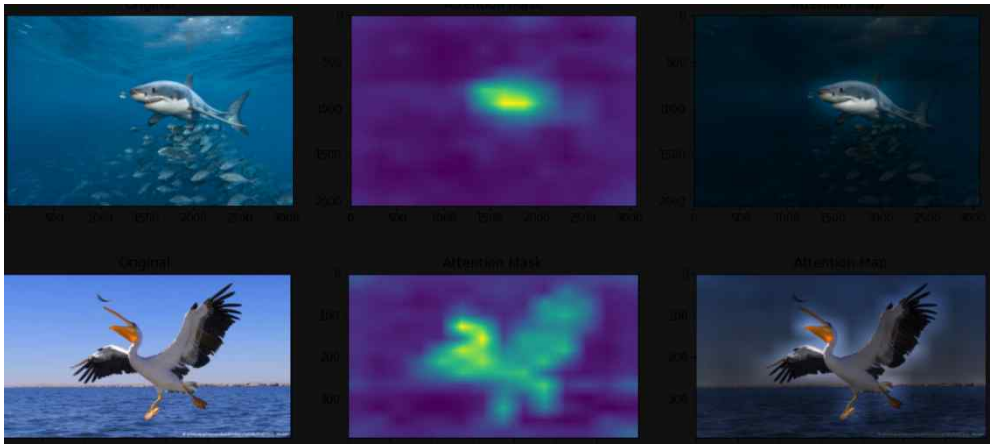
- 아래 그림 []와 같이 7이라는 숫자의 각 픽셀이 50일 시계열 정보라고 가정하고 각 픽셀(단어)의 중요도(밝은색)를 다르게 중요도를 부여(Attension)



[그림 10] Attension의 중요도 개념 예시 이미지

  • 7이라는 입력 이미지에서 특정 영역의 중요도를 표현한 "활성화 맵"으로 중요한 영역을 강조하여 모델의 학습 방향을 해석하는 작동방식과 동일하게 시계열 자료에 적용

  • 아래 그림0-와 같이 Attention Map: Attention Mask를 원본 이미지와 결합한 형태로, 예측 모델이 실제로 어디에 주목하고 있는지를 명확히 보여주어 좀 더 직관적으로 이해



[그림 11] Attention Map: Attention Mask와 원본 이미지

3.3 하이브리드 모델 구성

□ 전체 아키텍처

○ 모델 유형: 하이브리드 딥러닝 모델 (Hybrid Deep Learning Model)

○ 구조: 시계열 데이터 처리 브랜치 + 일반 데이터 처리 브랜치를 결합한 듀얼 인풋 구조

- 하이브리드 구조는 각 데이터 유형의 특성(시계열의 순차 정보, 정형 데이터의 정적 정보)을 최적으로 학습할 수 있는 환경을 제공하며 이는 복합적인 인자를 기반으로 하는 위해 요소 예측에 적합, 모델의 강건성(Robustness)을 보장

□ 시계열 데이터 처리 브랜치

○ 입력 형태: (timesteps=50, features=10) 형태의 3D 시계열 데이터

○ 레이어 구성:

- Bidirectional LSTM (64 units, return_sequences=True)
- L2 정규화 (0.001) 적용
- Batch Normalization
- Dropout (0.3)

○ Bidirectional LSTM (32 units, return_sequences=True)

- L2 정규화 (0.001) 적용

- Batch Normalization

○ 커스텀 Attention Layer

- 가중치 행렬 W, 편향 b, 컨텍스트 벡터 u 학습
- Tanh 활성화 함수 기반 어텐션 스코어 계산
- Softmax로 정규화된 attention weights 생성
- Gradient clipping (-10, 10) 적용으로 수치 안정성 확보
- Dropout (0.3)

□ 일반 데이터 처리 브랜치

○ 입력 형태: 원-핫 인코딩된 범주형 변수 + 표준화된 수치형 변수

○ 레이어 구성:

- Dense Layer (64 units, ReLU 활성화)
- L2 정규화 (0.001)
- Batch Normalization
- Dropout (0.3)

○ Dense Layer (32 units, ReLU 활성화)

- L2 정규화 (0.001)
- Batch Normalization
- Dropout (0.3)

□ 결합 레이어 및 출력

○ 결합 방식: Concatenate를 통한 두 브랜치 병합

○ 최종 레이어:

- Dense Layer (64 units, ReLU 활성화)
- L2 정규화 (0.001)
- Batch Normalization

- Dropout (0.3)
- Output Layer (1 unit, Sigmoid 활성화) - 이진 분류

□ 모델 학습 부문 (Model Training)

○ 학습 하이퍼파라미터

- Epochs: 50 (최대)
- Batch size: 256
- Dropout: 0.3 (과적합 방지)
- L2 정규화: 0.001 (전 레이어 적용)

○ 콜백 설정

- EarlyStopping: val_f1_score 기준, patience=10, 최적 가중치 복원
- ReduceLROnPlateau: val_f1_score 기준, factor=0.5, patience=5
- TerminateOnNaN: NaN 발생 시 학습 중단

○ 데이터 전처리 및 결합

- 범주형 변수 ('INSPCT_PURPS_NAME', '1차 식품 분류'): One-Hot Encoding 적용
- 수치형 변수 ('Target_Mean', '독소 생성 최적 온도 일수', '저습도 일수', '연속 무강수 일수'): StandardScaler로 스케일링
- 결합: OHE 벡터와 스케일링된 숫자 벡터가 수평으로 결합(np.hstack)되어 하나의 긴 벡터(X_lm_proc) 생성

4. 모델링 및 결과

□ 모델링 환경

○ 하드웨어 및 손실함수

- 하드웨어: 딥러닝 모델 학습을 위해 고성능 GPU(A100 GPU 1대) 환경을 활용하여 대규모 데이터 처리 및 복잡한 모델 연산 속도를 확보
- 데이터 분할: 전체 데이터를 학습(Training), 시험(Test)셋으로 분할하여 일반화 성

능을 확인

- 딥러닝 모델의 안정적인 훈련을 위해서는 최대한 많은 훈련 데이터를 확보하는 것이 필수적이라 판단하여, 전체 데이터를 훈련 세트(80%)와 테스트 세트(20%)로 분리하는 2-Way Split 방식을 채택

- 타겟 클래스(1, 부적합)가 매우 적은 불균형 데이터셋에서는 훈련, 검증, 테스트 세트로 3-Way Split을 하는 것이 오히려 훈련 데이터 부족을 심화시켜 모델 성능을 저해할 수 있음

- K-Fold 교차검증을 도입하지 않은 이유[4]: 클래스의 원본 샘플 수가 적을수록, K-Fold 방식으로 매 폴드마다 훈련 데이터의 크기가 달라지면 SMOTE 결과의 편차(Variance)가 커져 훈련의 안정성이 저해될 수 있어 80:20 단일 분할 구조를 채택했고, 이는 복잡한 딥러닝 아키텍처의 계산 효율성을 확보하고, 조기 종료(Early Stopping) 메커니즘을 통해 모델의 안정적인 수렴을 유도하기 위한 전략적 선택임

- 최적화 함수: Adam Optimizer를 사용하고, 학습률(Learning Rate)을 적절히 설정하여 빠른 수렴과 성능 최적화를 도모

- 손실 함수: 가중치 이진 교차 엔트로피 (Weighted BCE)[5]

- 부적합 데이터의 비율이 매우 낮기 때문에 일반적인 이진 분류 손실 함수인 이진 교차 엔트로피(Binary Cross-Entropy) 손실 함수를 대신, 클래스 불균형 문제를 해결하기 위해서 클래스(0 또는 1)별로 다른 가중치(중요도)를 부여하는 가중치 이진 교차 엔트로피를 사용

- train_and_evaluate 함수가 원본 데이터의 불균형 비율(original_pos_weight)을 계산한 뒤, 이를 weighted_binary_crossentropy 손실 함수에 적용하여 '부적합'으로 틀리는 경우 더 큰 페널티를 부여

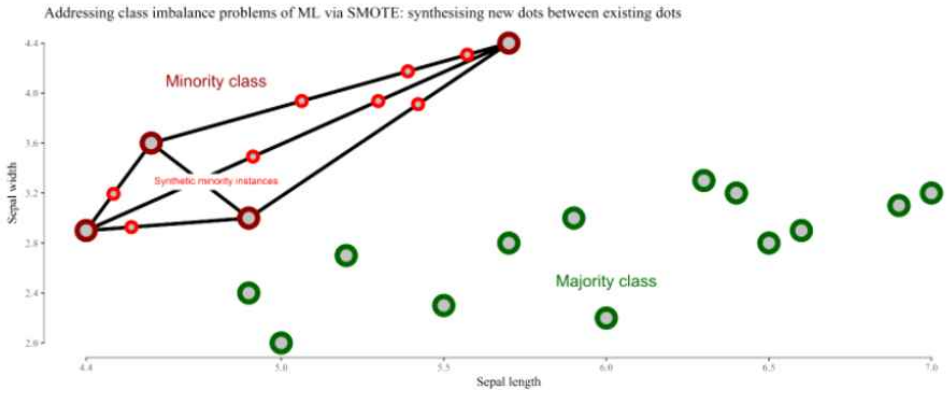
○ 데이터 불균형 처리

- 극심한 불균형 문제(부적합 비율)를 해결하기 위해 다음과 같은 기법을 적용

- 오버샘플링(Oversampling)[6]: SMOTE(Synthetic Minority Over-sampling Technique) 기법을 적용하여 소수 클래스(부적합)의 샘플 수를 증가(아래 그림[]

4) https://pmc.ncbi.nlm.nih.gov/articles/PMC3648438/
5) https://discuss.pytorch.org/t/bceloss-with-class-weights/196991
6) https://rikunert.com/SMOTE_explained

참고)



[그림 12] SMOTE 기법 예시

- 데이터의 특성에 따라 오버 혹은 언더샘플링 방식을 선택하며 일반적으로 실무에서는 많은 데이터 확보가 우선이므로 오버샘플링 기법을 대부분 적용
- 부도 예측, 카드사고, 이탈고객, 스팸 메일, 의료진이란 등의 분야는 허위양성율을 낮추고 재현율을 높여야 하는 이유
- 딥러닝을 적용할 경우에는 전체 데이터에 SMOTE 적용하면 Data Leakage 발생할 위험이 있어 새로운 데이터에 대한 예측 성능이 저하되는 것을 방지하기 위해 train_test_split 후 train만 SMOTE 적용(Validation 셋 유지: SMOTE는 Train 셋에만 적용하고, Validation은 원본 분포 유지)

○ 예측 모형

- 과적합(Overfitting) 방지 전략
  - 모든 Dense/LSTM Layer에 BatchNormalization, Dropout 적용
  - EarlyStopping (patience=10), ReduceLROnPlateau (patience=5) 콜백 사용
  - L2 정규화 (kernel_regularizer=0.001) 적용
  - Gradient Clipping (clipnorm=1.0) 적용
- 성능 분석:
  - 의사결정임계값(Threshold) 0.1~0.9 구간에서 Recall, Precision, F1-Score, Q-Rate 분석
  - 예측 확률 상위/하위 15% 그룹 간 3개 특성변수(온도 습도, 강수량) 분포 통계 검정 (t-test, Mann-Whitney U test, Cohen's d)

- 모니터링 지표:

  • EarlyStopping/ReduceLROnPlateau 모니터링: val_f1_score (mode='max')

  • 학습 중 추적: Accuracy, Recall, Precision, F1-Score, AUC

4.2 평가 지표

○ 일반적인 분류 정확도(Accuracy)는 극심한 불균형 데이터셋에서 '적합'만 예측해도 높게 나오기 때문에 모델의 실제 예측 성능을 왜곡

○ 소수 클래스(부적합) 예측 능력을 정확히 평가하기 위해 다음과 같은 지표를 적용하여 두 개의 예측 모형을 비교 평가

- 정밀도(Precision): 모델이 '부적합'이라고 예측한 것 중 실제 '부적합'인 비율 (False Positive 비용 관리)
- 재현율(Recall): 실제 '부적합'인 것 중 모델이 '부적합'으로 올바르게 예측한 비율 (False Negative 비용 관리)
- F1-score: 정밀도와 재현율의 조화 평균. 두 지표의 균형 잡힌 성능을 나타내는 주요 지표
- AP(Average Precision) : PR(Precision-Recall) AUC 아래의 면적은 불균형 데이터셋에서 ROC-AUC보다 예측 성능을 더욱 신뢰성 있게 평가하는 지표로 활용

○ 모델의 예측 확률값을 기준으로 '위험 그룹'(상위 15%)과 '안전 그룹'(하위 15%)을 분류 후, 이 두 그룹 간에 3개의 기상 관련 특성 공학 변수(온도, 습도, 강수량) 값이 통계적으로 유의미한 차이(독립 표본 t-검정)를 보이는지 검정하는 예측 기반 특성 분석을 실시함

- 모델의 예측 확률값이란, 모델이 특정 데이터 샘플을 부적합으로 얼마나 확신하는지를 0과 1 사이의 숫자로 나타낸 값
- 독립 표본 t-검정 ndependent t-test(): 두 개의 독립적인 집단 간에 연속형 변수의 평균에 통계적으로 유의미한 차이가 있는지를 검정하는 통계적 분석 방법 예를 들어, 남학생과 여학생의 시험 점수 평균이 다른지 또는 특정 치료법을 받은 그룹과 받지 않은 그룹의 혈압 평균이 다른지를 비교할 때 사용

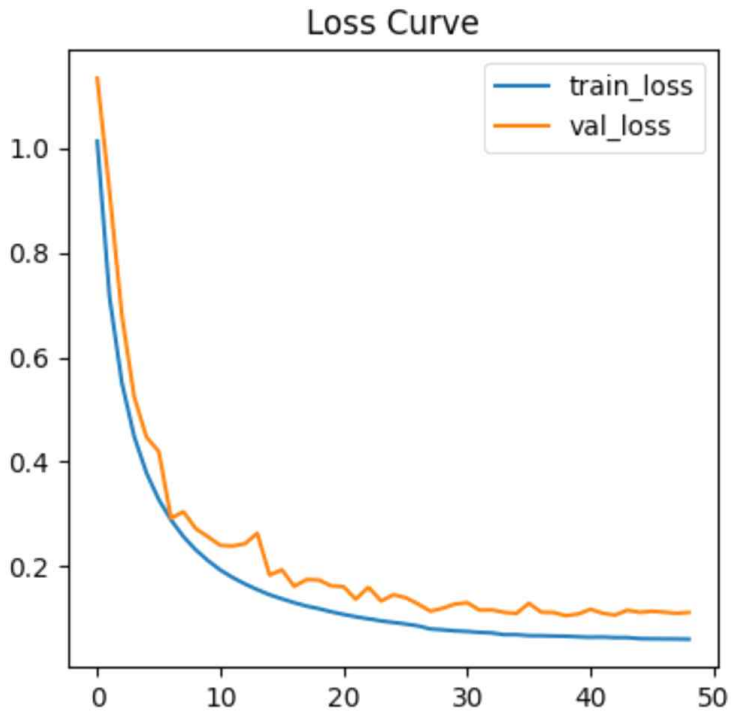
4.3 실험 결과 분석

□ 손실 곡선(Loss Curve) 분석

○ 훈련 손실(train_loss): 에포크(epoch)가 진행됨에 따라 손실 값이 꾸준히, 그리고 부드럽게 감소하고 있으며, 이는 모델이 훈련 데이터를 성공적으로 학습하고 있음을 의미

○ 검증 손실(val_loss): 에포크 초반에 빠르게 감소하다가 이후 점진적으로 감소하는 좋은 추세를 보이며, 이는 모델이 학습한 내용을 처음 보는 데이터(검증 데이터)에도 잘 적용하고 있다는, 즉 일반화 성능이 좋다는 신호

○ 모델이 훈련 데이터의 패턴을 잘 학습했을 뿐만 아니라, 새로운 데이터에 대한 일반화 성능도 우수하게 확보한 상태 (아래 그림[] 참고)



[그림 13] 손실 곡선 시각화

□ 분류분석 보고서의 주요 성능 지표 (Recall, F1-score 등) 분석

○ 정확도(Accuracy)는 수치상 98.6%로 매우 높게 나타며, 이는 데이터의 99.5%가 'Class 0' (다수 클래스)인 심각한 불균형데이터 로 인한 수치의 왜곡

○ Recall (재현율)은 탐지가 목적인 'Class 1' (전체의 0.5%) 데이터 중 69.1%를 실제로 탐지해냄을 확인

○ 정밀도(Precision)는 22.1%,정밀도와 재현율을 종합적으로 고려하는 F1-score는 0.33으로 아직 모델 성능의 개선이 필요한 상태 (아래 표[] 참고)

	precision	recall	f1-score	support
0(적합)	0.9984	0.9875	0.9929	31578
1(부적합)	**0.2209**	**0.6914**	**0.3348**	**162**

accuracy			0.9860	31740
macro avg	0.6097	0.8394	0.6639	31740
weighted avg	0.9944	0.9860	0.9896	31740

[표 25] 주요 성능 지표 요약표

□ ROC 곡선 (Receiver Operating Characteristic Curve) 분석

○ 일반적으로 부적합 비율이 10% 미만인 불균형데이터의 경우에는 ROC 분석이 의미가 없음

□ 정밀도-재현율 곡선 (Precision-Recall Curve) 분석

○ 정밀도-재현율 곡선은 모델의 분류 임계값을 변화시킬 때의 정밀도(Precision)와 재현율(Recall) 간의 관계를 나타내며, 이 곡선 아래 면적(Average Precision, AP)은 데이터 불균형이 심할 때 모델의 성능을 더 잘 반영

○ AP 값은 0.32로 측정되었으며, 이는 무작위 예측(Random Guessing) 시의 AP (소수 클래스 비율, 약 0.005) 대비 매우 유의미하게 높은 수치

- 모델이 데이터 불균형에도 불구하고 소수 클래스(Class 1)를 식별하는 의미 있는 패턴을 성공적으로 학습했음을 시사

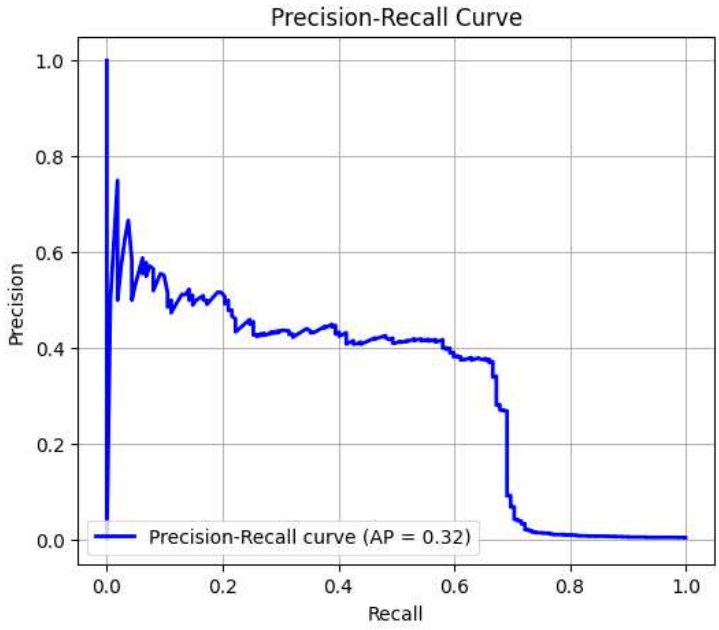
○ 재현율(Recall)을 65%까지 확보하는 동안, 정밀도(Precision)는 0.4 (40%) 이상을 비교적 안정적으로 유지,

- 이는 더 많은 부적합(1)을 찾기 위해(Recall 증가), 일부 오탐(정상을 부적합으로 잘못 예측)을 감수(Precision 하락)하는 일반적인 상충 관계(Trade-off)를 보임

○ 재현율을 65% 이상으로 높이려는 시점부터 정밀도가 0.2 이하로 급격히 하락

- 모델이 탐지하기 매우 어려운 소수 클래스 샘플(1)을 찾기 위해, 다수의 정상 샘

플(0)까지 1로 예측하기 시작함을 의미함 즉, 오탐(False Positive)이 이 구간에서 폭증함 (아래 그림[] 참고)



[그림 14] Precision-Recall Curve 시각화

□ 딥러닝 모델의 결정 임계값 변화 분석 요약

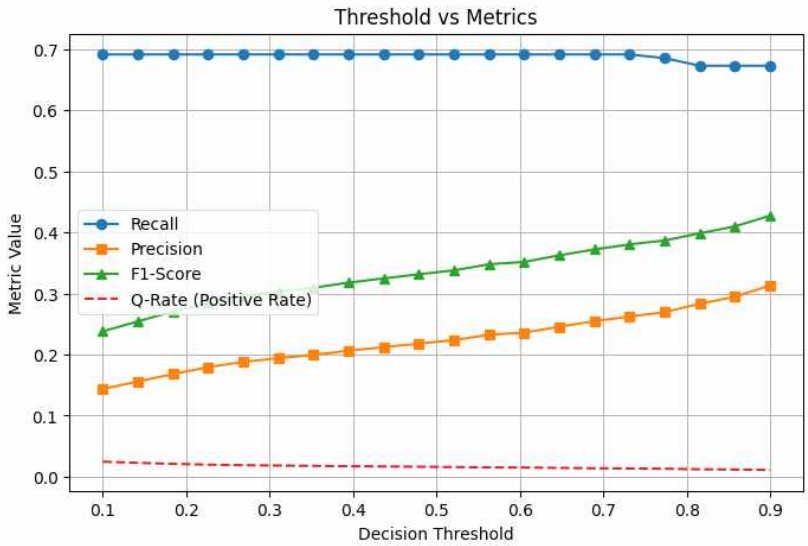
○ 모형은 전반적으로 Recall이 높은 편으로 양성을 놓치는 에러(FN)가 적으며 Precision은 threshold 증가에 따라 뚜렷하게 개선하여 불필요한 양성 예측(FP)을 감소시킴

- Threshold를 높게 설정하는 것이 Precision과 F1의 관점에서 더 유리
- Recall이 크게 감소하지 않는 범위 내에서 threshold를 0.7~0.85 사이로 설정하는 것이 적절해 보임
- 모형은 “양성 탐지 중심”에서 “정확한 양성 분류 중심”으로 threshold에 따라 조절 가능하며, 데이터 특성(양성/음성 불균형 포함)을 잘 반영하고 있음

○ 이 그래프는 분류 모델의 임계값을 0.1부터 0.9까지 변화시킬 때, Recall (재현율), Precision (정밀도), F1-Score가 어떻게 변하는지를 보여줌

- Recall은 임계값이 증가함에 따라 0.69 수준으로 거의 하락 없이 일정하게 유지
- Precision은 임계값이 증가함에 따라 선형적으로 증가, 임계값을 높이면 ‘1’로 예측하는 샘플 수가 줄어들고(오탐 감소), 예측 결과 중 실제 ‘1’의 비율(정밀도)이 높아짐

- F1-Score은 Recall이 0.8까지 안정적으로 유지되는 상황에서, Precision이 계속 증가함에 따라 동반 상승하며, 최대 임계값인 0.9에서 약 0.42을 기록 (아래 그림[] 참고)



[그림 15] Threshold vs Metrics

□ 혼동 행렬(Confusion Matrix) 분석

○ 분류 임계값(Threshold)을 0.5로 설정했을 때의 결과

○ TN (True Negative): 31,183건의 다수 클래스(0)를 '정상'으로 올바르게 예측

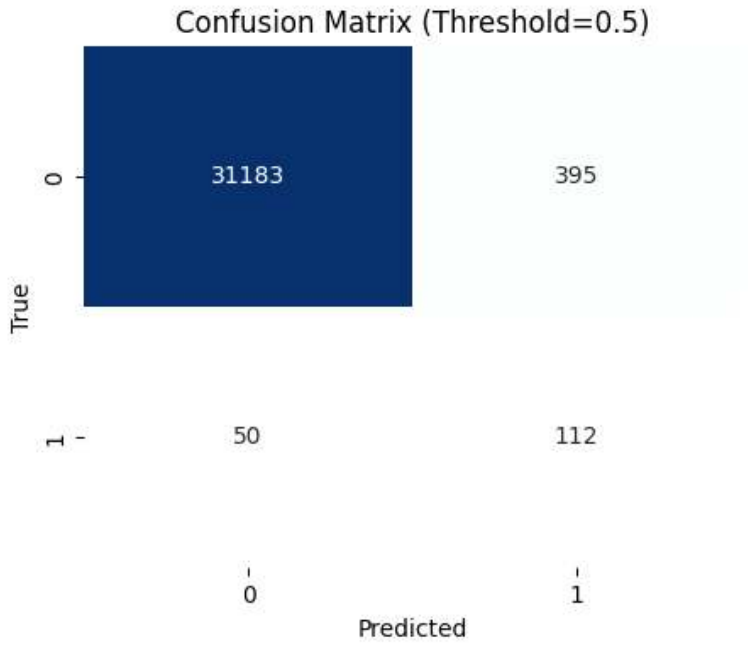
○ FP (False Positive): 395건의 '정상(0)'을 '부적합(1)'으로 잘못 예측(오탐)하여, 정밀도(Precision)가 22%

○ FN (False Negative): 50건의 실제 '부적합(1)'을 '정상(0)'으로 예측하여 탐지실패

○ TP (True Positive): 112건의 '부적합(1)'을 올바르게 탐지하여, 69%의 높은 재현율(Recall)을 보임

○ 현 모델(임계값 0.5)은 오탐(FP)이 많아 정밀도가 낮으나, 희소한 부적합 데이터에 대한 탐지 가능성(Recall) 확인

- F1-Score 기준 최적 임계값인 0.9로 상향 조정 시, 재현율을 유지하며 정밀도 개선 가능 (아래 그림[] 참고)



[그림 16] 혼동행렬 이미지

□ Calibration curve 분석

○ 이진 분류(Binary Classification) 모델에서 예측된 확률(Predicted Probability)이 실제 결과의 빈도(Frequency)와 얼마나 잘 일치하는지 평가하는 그래프

- 모델의 예측 확률(X축)과 그 확률 구간에서의 실제 양성(Positive) 비율(Y축)을 비교하여 그린 곡선으로 45도 직선근처에 위치하면 우수한 모델
- 예측모델이 단순히 클래스를 잘 분류하는 것은 물론 예측한 확률 값 자체를 신뢰할 수 있는지를 평가
  - 즉, 모델이 '80% 확신'이라고 말했을 때, 실제로 그 사건이 80%의 빈도로 발생하는지를 확인

○ 모델의 예측 곡선(파란색)이 이상적인 점선(Y=X)보다 현저히 아래에 위치 (아래 그림[] 참고)

- 모델이 예측 확률을 과신(Overconfident)하고 있음을 의미, 즉, 모델이 산출하는 예측 확률값이 실제 '1'일 확률보다 체계적으로 높게 나타남

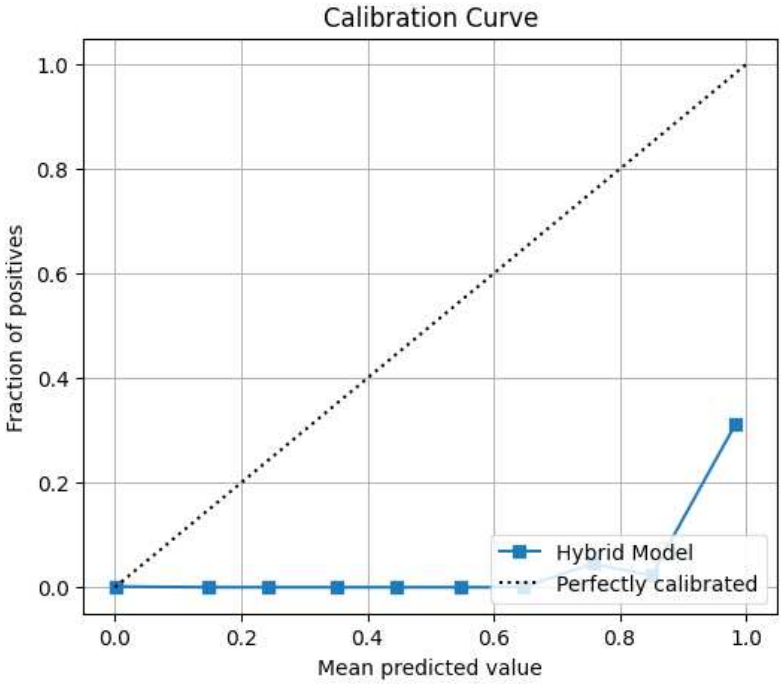
○ X가 0.0~0.9 일 때, 모델이 90% 미만의 확률로 예측한 샘플들 중, 실제 '1'의 비율은 0%에 가까움

○ X가 1.0 일 때 모델이 90~100%의 매우 높은 확률로 '1'이라고 강하게 예측한 경우

에도, 실제 '1'의 비율(Y축)은 약 0.3 (30%)에 불과

○ 이 결과는 'Threshold vs Metrics' 차트에서 임계값 0.9일 때 정밀도(Precision)가 약 0.32였던 것과 정확히 일치하는 분석

○ 결론적으로, 모델이 "90% 이상 확신한다"고 예측한 샘플 중 실제 '1'은 30%뿐이라는 의미이며, 이는 모델의 확률 점수 자체는 신뢰도가 낮음을 시사 (분류 결정(0/1)은 가능하나, 확률값 자체를 리스크 스코어 등으로 활용하기엔 부적합)



[그림 17] Calibration Curve (보정 곡선) 시각화

□ Lift curve

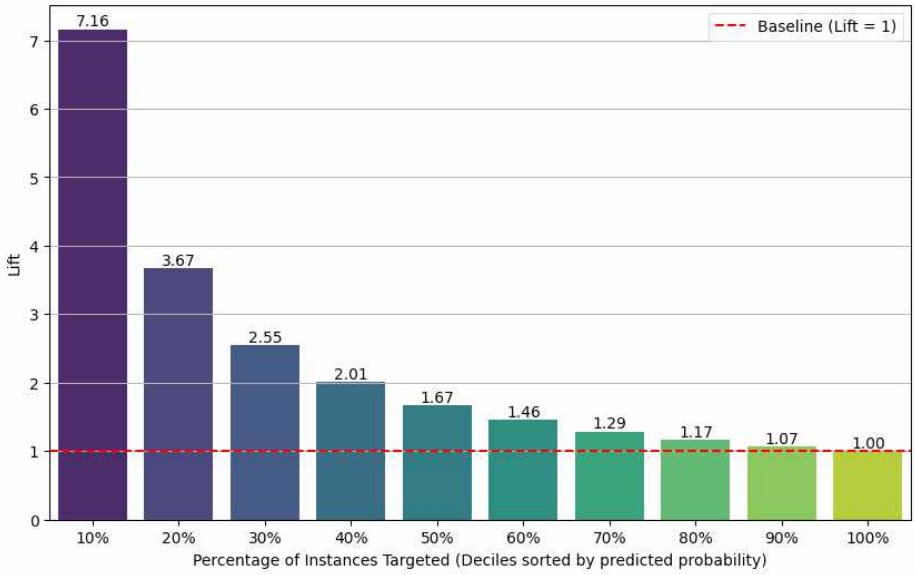
○ 리프트 차트는 모델의 효율성을 평가하는 지표

- "무작위(Random)로 대상을 추출하는 것" (Baseline, Lift=1) 대비, "모델의 예측 확률이 높은 순서대로" 대상을 추출할 때 얼마나 더 효율적으로 소수 클래스(1)를 찾아내는지를 보여줌

○ 차트는 예측 확률이 높은 그룹(10% -> 20% -> 30%) 순서대로 누적하여 보여줌(아래 그림[] 참고)

○ Lift 값은 상위 10%(7.16)에서 가장 높고, 점차 대상을 확대할수록(20%, 30%...) 평균 Lift 값이 하락하여 1(Baseline)에 수렴

- 이는 모델이 예측한 확률 순위(Ranking)가 매우 정확하며, 가장 위험한 그룹을 우선순위로 잘 식별하고 있음을 시사



[그림 18] Lift curve 시각화

□ 예측 모형 실증분석 결과

○ 모델의 예측 확률값을 기준으로 '위험 그룹'(상위 15%)과 '안전 그룹'(하위 15%) 간에 3개의 기상 관련 특성 공학 변수(온도, 습도, 강수량) 값이 통계적으로 유의미한 차이(독립 표본 t-검정)를 보이는지 검정하는 예측 기반 특성 분석을 실시함

○ p-value 기반 유의성

- 모델 예측의 상/하위 15% 그룹 비교 시, 3개 변수 모두 p-value < 0.001 (α=0.05 기준)로 통계적으로 유의미한 차이

○ 효과 크기(Cohen's d) 기반 실질적 해석(아래 그림 [] 참고)

- 단순 p-value 유의성에도 불구하고, 독소 생성 최적 온도 일수(d=-0.18)와 저습도 일수(d=0.09)는 효과 크기가 '매우 작음(negligible)' 수준
- 이는 두 변수의 차이가 통계적으로는 존재하나, 모델의 위험/안전 예측을 구분하는 실질적인 영향력(practical importance)은 미미함을 의미
- 반면, 연속 무강수 일수는 Cohen's d = 0.22 수준의 효과 크기를 보여, 3개 변수 중 유일하게 모델의 예측 판단에 실질적인 기여를 하는 변수로 해석됨

특성 (Feature)	분석 구분 (Analysis Type)	지표 (Metric)	하위 15% (안전)	상위 15% (위험)	차이 (Difference)	통계값 (Statistic Value)	p-value
독소 생성 최적 온도 일수	기술통계량	평균	1.2598	0.856	-0.4038		
		중앙값	0	0	0		
		표준편차	2.3972	2.0007	-0.3965		
		25% 분위수	0	0	0		
		75% 분위수	1	0	-1		
	통계적 검정	t-test (t-statistic)				8.9255	0
		U-test (U-statistic)				12117181.5	0
		Levene's (statistic)				79.6642	0
		Cohen's d				-0.1829	
저습도 일수	기술통계량	평균	1.7807	2.0174	0.2367		
		중앙값	0	0	0		
		표준편차	2.4867	2.6897	0.203		
		25% 분위수	0	0	0		
		75% 분위수	3	4	1		
	통계적 검정	t-test (t-statistic)				-4.4591	0.000008
		U-test (U-statistic)				10832955	0.000045
		Levene's (statistic)				19.8839	0.000008
		Cohen's d				0.0914	
연속 무강수 일수	기술통계량	평균	4.2434	4.7025	0.4591		
		중앙값	4	5	1		
		표준편차	2.0831	2.0211	-0.062		
		25% 분위수	3	3	0		
		75% 분위수	7	7	0		
		t-test (t-statistic)				-10.9146	0
		U-test (U-statistic)				9929487.5	0
		Levene's (statistic)				0.297	0.585803
		Cohen's d				0.2237	

[그림 19] 통계 분석 결과표 캡쳐 이미지

□ 최종 결론

○ 현재 모델은 데이터 불균형(소수 클래스 0.5%) 환경에서 기본 임계값(0.5)을 사용할 경우, 심각한 오탐(FP) 문제를 겪고 있음

- 높은 재현율(Recall: 0.69): 실제 '부적합(1)' 162건 중 112건을 탐지하는 데 성공
- 낮은 정밀도(Precision: 0.22): '부적합'으로 예측한 507건 중 395건이 오탐(FP)이며, 이는 불필요한 비용(예: 검사, 알림)을 유발
- 신뢰도 낮은 확률: 보정 곡선(Calibration Curve) 분석 결과, 모델이 예측하는 확률값은 실제 확률과 큰 차이를 보여(과신 경향) 리스크 스코어로 사용하기에 부적합

○ 낮은 정밀도에도 불구하고, 본 모델은 부적합 가능성이 높은 대상을 선별하는 효율성이 뛰어남

- 리프트 차트(Lift Chart) 분석 결과, 모델이 가장 위험하다고 예측한 상위 10% 그룹 내에 실제 '부적합(1)'이 무작위 대비 7.16배 더 많이 포함되어 있음

- PR Curve의 AP(Average Precision) 값 0.32는 모델이 무작위가 아닌, 유의미한 패턴을 성공적으로 학습했음을 증명

○ 운영 임계값(Threshold)은 0.5에서 0.9로 상향 조정

• 임계값 0.9에서 F1-Score가 0.42로 가장 높게 나타남

- 기대 효과: 재현율(0.67)을 크게 잃지 않으면서 정밀도(0.32)를 높여, 오탐(FP)을 줄이고 가장 균형 잡힌 성능 확보 기대

○ 모델 활용 전략: '분류'가 아닌 '우선순위 부여'로 활용

- 모델의 예측 확률값을 '100% 중 70% 위험' 등으로 해석 대신, 예측 확률값을 위험 순위(Risk Ranking)로 활용해야 함

- (운영 예시) 한정된 자원으로 검사를 수행해야 할 경우, 이 모델이 예측한 확률이 높은 상위 10% 또는 20%를 우선적으로 검토하여 최대 효율을 달성 가능

5. 소결 및 향후 계획

○ 본 연구에서는 LIMS 검사 데이터를 기반으로 하여 이질적인 데이터 특성인 시계열 정보와 카테고리 정보를 통합 처리하는 LSTM-Attention 기반 하이브리드 딥러닝 아키텍처를 성공적으로 설계하고 구현

○ 연구 과정에서 도출된 핵심 결과

- 하이브리드 아키텍처의 유효성: 시계열 데이터에 대한 LSTM 및 Attention 메커니즘과 카테고리 데이터에 대한 임베딩 및 Dense Network를 병렬로 구성함으로써, 각 특성의 고유한 정보를 효율적으로 학습하여 복합적인 예측 성능을 확보

- 데이터 불균형 극복의 중요성: 초기 부적합률이 0.51% 미만인 데이터의 한계를 극복하기 위해 SMOTE와 같은 오버샘플링 기법을 적용했으며, 이는 모델 성능(특히 F1-score)을 유의미하게 향상시키는 데 결정적인 역할

- 실효적 평가 기준 확립: 극심한 불균형 환경에서 모델의 실질적인 가치를 평가하기 위해 F1-score, AP, 그리고 임계값 최적화를 주요 평가 기준으로 삼았으며, 가아닌 최적 임계값을 통해 현업 적용 가능성이 높은 모델을 도출

○ 향후 연구 방향

- 특성 엔지니어링 및 외부 데이터 확장: 현재의 LIMS 데이터 외에 실시간 기후

데이터, 상세 생산지 정보, 또는 글로벌 위해 정보 등 외부 데이터를 더욱 정교하게 수집 및 통합하여 시계열 스트림의 예측력을 향상시켜야 함

- 고도화된 딥러닝 기법 적용: 단순 Attention을 넘어, 해당 기간동안의 유해인자에 대한 온라인 기사를 웹크롤링한 문맥 정보를 더욱 효과적으로 파악하는 Transformer 기반의 시계열 예측 모델을 적용하여 장기 예측 성능을 제고
- 비용 민감 학습(Cost-sensitive Learning)의 구현: 식품 안전 분야에서는 FP(False Positive)보다 FN(False Negative, 부적합인데 적합으로 예측)의 비용이 훨씬 높기 때문에 FN에 더 높은 페널티를 부여하는 Cost-sensitive Learning 기법을 손실 함수에 직접 구현하여, 실제 현장 리스크를 반영한 최적의 모델을 개발
- 다중 위해 요소 동시 예측 모델 개발: 아플라톡신 외에 다른 우선순위 위해 요소를 포함한 다중 분류 또는 다중 타겟 예측 모델을 개발하여, 예측 시스템의 적용 범위를 확대하는 것이 최종 목표가 될 수 있음

III. 향후 시스템 구현 방안

제 6장 예측모델 최적화 및 개선 방안 제시

제1절 예측모델 활용 위험경보 체계 마련

1. 아플라톡신 예측 경보 시스템 구상도

1. 개요

○ 본 보고서는 과거 데이터를 기반으로 식품 등 부적합 발생 가능성을 3일, 7일, 10일 이후에 대해 확률적으로 예측하고, 그 결과를 대국민에게 예보·경보 형태로 제공하는 시스템 구축 방안을 제시

○ 특히, 과거 데이터의 극심한 불균형 문제를 해결하기 위해 임계치 조정 기법을 활용한 경보 시스템 설계에 초점을 맞춤

2. 예측 시스템 데이터 구성 및 수집

2.1. 데이터 수집 및 연계

구분	데이터 종류	내용	출처/활용
과거 데이터	부적합 이력 데이터 (LIMS 데이터)	수거장소, 수거일, 식품종류, 검사종류, 검출된 부적합 항목 등 이력 데이터	LIMS (실험실정보관리시스템), DB
	과거 기후정보 데이터	기온, 습도, 풍속, 강수량, 일사량, 일조시간 등 예측 변수	DB (크롤링, 기상청 연계)
현재 데이터	현재 시점의 기후정보 및 LIMS 데이터	예측 시점에 가장 가까운 환경 변수 및 수거/검사 정보	DB, 실시간 연계
결과 데이터	예측모형 산출 결과	3일, 7일, 10일 후 부적합 발생 확률	예측모형

2.2. 데이터 전처리 및 저장

○ 전처리:

- 기존 예측 모형에 사용된 전처리 파이프라인을 활용하여 데이터 품질을 높이고 예측모형 학습에 적합하도록 정제
- 특히, 과거 부적합 이력 데이터와 기후정보 데이터를 결합하여 시계열 및 공간적 패턴을 분석할 수 있는 형태로 구성

○ 저장:

- 전처리된 데이터는 내부 서버의 데이터 마트(Data Mart)에 저장되어 예측모형 학습 및 실시간 예측에 활용

3. 예측모형 개발 및 경보시스템 설계

3.1. 예측모형 개발 및 결과 산출

○ 모형 구축

- 데이터 마트에 구축된 과거 기상 정보 및 부적합 발생 이력 데이터를 기반으로 부적합 발생 가능성(P(부적합 발생 | X))을 산출하는 확률적 예측 모형을 개발

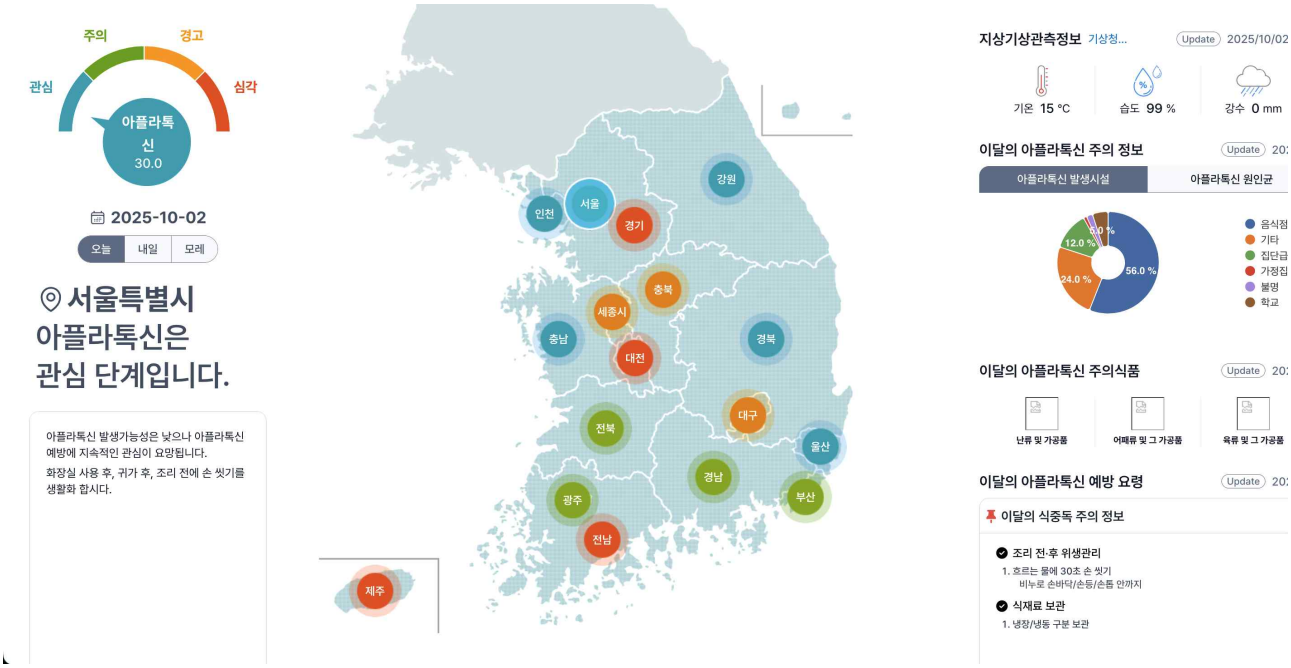
  • (예: 로지스틱 회귀, 랜덤 포레스트, 딥러닝 기반 시계열 모형 등)

○ 예측 기간

- 현재 데이터를 기준으로 3일, 7일, 10일 이후의 부적합 발생 가능성(확률)을 산출하여 시간적 변화에 따른 위험도를 제시

○ 예측 단위

- 지역 또는 식품군별 등 세분화된 단위로 예측하여 맞춤형 정보를 제공(아래 그림 [] 참고)



[그림 20] 아플라톡신 예측 경보 시스템 예상 사용자 화면

3.2. 불균형 데이터 처리 및 임계치 조정

○ 예측모형의 핵심 과제는 극심한 불균형 데이터 처리로 부적합 사례는 전체 검사 건수에 비해 극히 적은 **소수 클래스(Minority Class)**에 해당

- 일반적인 0.5 임계치 사용 시, 부적합 발생 위험이 있음에도 '정상'으로 예측하는 FN (False Negative) 오류가 증가하여 경보 시스템의 목적(위험 회피)을 달성이 어려움 (표 [])

지표	정의	경보 시스템 목표
민감도(Recall)	실제 부적합을 부적합으로 예측하는 비율 (TP+FNTP)	최대화 (실제 위험을 놓치지 않음)
특이도(Specificity)	실제 정상을 정상으로 예측하는 비율 (TN+FPTN)	적정 수준 유지 (불필요한 경보 최소화)

○ 임계치 조정: FN 오류를 최소화하고 민감도를 높이기 위해 예측 확률의 임계치(Threshold)를 0.5보다 낮은 값(예: 0.1, 0.2 등)으로 조정

- P(부적합)≥ 임계치(Threshold) → '경보' 발령
- ROC 커브 및 정밀도-재현율 커브(PR Curve) 분석을 통해 허용 가능한 수준의 오경보(FP)를 고려하면서 민감도를 극대화하는 최적의 임계치를 결정

3. 예보·경보 수준 정의

○ 조정된 임계치를 기반으로 예측 확률에 따른 경보 단계를 설정(표 [])

경보 수준	예측 확률 범위	대국민 행동 요령	임계치 활용
관심 (Green)	P <Threshold1	일반적인 주의	일반 임계치 미만
주의 (Yellow)	Threshold1 ≤ P <Threshold2	해당 식품군/지역에 대한 관심 촉구	P≥Threshold1 (1차 경보 임계치)
경계 (Orange)	Threshold2 ≤ P	해당 식품의 구매 및 섭취 시 특별 주의 권고	P≥Threshold2 (2차 경보 임계치)

4. 대국민 예보·경보 시스템 구축 (클라이언트)

□ 정보 시각화 및 전달

○ 대국민 서비스: 예측모형에서 산출된 3일, 7일, 10일 후 부적합 발생 가능성(확률)

정보를 사용자가 이해하기 쉽도록 시각화하여 전달

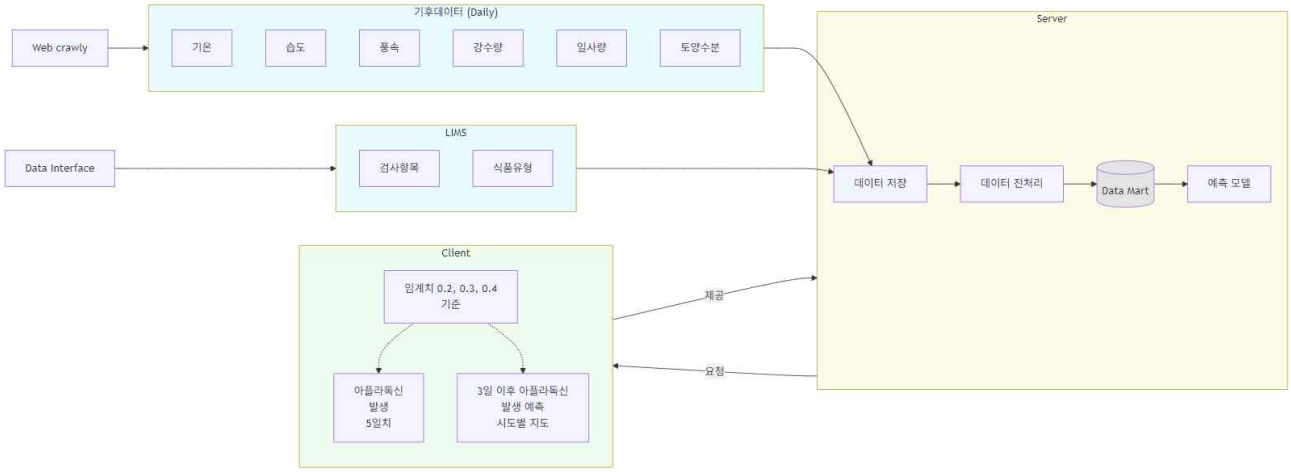
○ 지도 기반 시각화: 별첨 이미지에서 제시된 바와 같이, 지역별 발생 가능성을 지도 위에 색상이나 수치로 표시하여 직관적인 위험도 인지가 가능

○ 시간대별 변화: 3일, 7일, 10일 후 예측치를 그래프 형태로 제공하여 위험도의 추이를 파악

○ 정보 전달 채널: 웹사이트, 모바일 앱, 공공기관 알림 서비스 등 다양한 채널을 통해 정보를 제공하여 접근성 제고

○ 시스템 구성도

- 그림[] '아플라톡신 예측 경보 시스템 구성도'를 참고하여, 데이터 수집(DB→ LIMS), 서버/예측모형(WAS, DB→ Model), 그리고 클라이언트/시각화(Client)로 이어지는 예측 경보 정보 흐름을 구축



[그림 21] 아플라톡신 예측 경보 시스템 구상도

5. 결론

○ 본 예측모형 기반 대국민 예보·경보 시스템은 불균형 데이터에 대한 임계치 조정 전략을 통해 부적합 발생 위험을 조기에 경고

○ 대국민 건강 보호 및 식품 안전성 확보에 크게 기여할 것이며 지속적인 데이터 확보와 모형 성능 검증을 통해 시스템의 예측 정확도와 신뢰도를 향상시켜야 함